

## A performance comparison of large language models in solving multiple-choice physics problems based on multimodal input conditions

Jaebong LEE\*

Korea Institute for Curriculum and Evaluation, Jincheon 27873, Korea

(Received 6 April 2026 : revised 1 May 2026 : accepted 18 May 2026)

This study compared the performance of large language models (LLMs) in solving Korean high school physics multiple-choice questions under different multimodal input conditions: text only, image only, and combined text and image. For this purpose, the College Scholastic Ability Test (CSAT) Physics I questions were presented to seven models, and their accuracies were compared. The results showed substantial differences in performance depending on the models' generation and reasoning ability. The top-performing model showed high accuracy across all conditions, with the best results in the text-image condition. For diagram-based questions, visual processing and text-image integration were important. These findings suggest that LLMs can be actively used in physics education and offer several suggestions for their application.

Keywords: Large language models (LLMs), Multimodal, Problem solving ability, Prompt engineering, AI evaluation

## 거대 언어 모델의 멀티모달 입력 조건에 따른 선다형 물리 문항 풀이 성능 비교

이재봉\*

한국교육과정평가원, 진천 27873, 대한민국

(2026년 4월 6일 받음, 2026년 5월 1일 수정본 받음, 2026년 5월 18일 게재 확정)

본 연구는 거대 언어 모델(LLMs)의 한국어 고등학교 물리 선다형 문항에 대한 해결 성능을 멀티모달 입력 조건(텍스트, 이미지, 텍스트+이미지 결합)에서 비교하고 교육적 시사점을 도출하고자 하였다. 이를 위해 최신 7종의 모델을 활용하여 수능 물리학I 20개 문항의 정답률을 비교하였다. 연구 결과, 모델의 세대와 추론 능력에 따라 문제 해결 성능에 차이가 나타났는데, 최상위 모델은 모든 조건에서 안정적으로 높은 정답률을 보였으며, 전반적으로 텍스트와 이미지를 함께 제공할 때 정확도가 가장 높았다. 다만, 그림 해석이 중요한 문항에서는 모델의 시각 정보 처리 및 추론 능력이 정답을 좌우하는 핵심 요소로 작용했다. 연구에서는 LLMs의 정확성을 바탕으로 물리 교육에 활용할 수 있는 가능성을 확인하였으며, 관련하여 물리교육에 활용하기 위해 필요한 내용에 대해 논의하였다.

Keywords: 거대 언어 모델, 멀티모달, 문제 해결 능력, 프롬프트 엔지니어링, 인공지능 평가

\*Correspondence to: [jblee@kice.re.kr](mailto:jblee@kice.re.kr)



This is an Open Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/4.0>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

## I. 서 론

최근 거대 언어 모델(Large Language Models, LLMs)을 중심으로 인공지능(AI)이 빠르게 발전하면서 성능이 인간의 추론 능력에 근접한 수준에 이르렀고, 교육 분야 특히 물리 교육에서도 많은 변화의 가능성을 보여주고 있다 [1]. 거대 언어 모델은 서적이나 인터넷 등과 같은 다양한 출처에서 수집된 대규모 텍스트를 수십억 개 이상의 파라미터로 이루어진 인공신경망으로 학습해서 자연어를 이해하거나 생성해 내는 언어 모델이다. 거대 언어 모델의 핵심은 문장 요소 간의 관계에 기인한 단어 시퀀스 사이의 맥락적 의미를 파악할 수 있도록 하는 트랜스포머 아키텍처인데, 주어진 질문(입력)에 확률적으로 가장 적절한 응답을 생성함으로써 언어의 패턴, 문맥, 의미를 파악할 수 있도록 해 준다 [2]. 특히 2018년 Google이 발표한 BERT 이후 거대 언어 모델 연구는 빠르게 확장되었다. 이어 2022년 11월 챗봇 형태의 인터페이스를 가진 ChatGPT가 공개되고 일반인도 쉽게 접근하고 활용할 수 있게 되면서 확산하는 계기가 되었다. 현재, 대표적인 모델로 OpenAI의 GPT-3.5를 비롯하여 GPT-4, 멀티모달 성능이 강화된 GPT-4o, 논리적 추론 능력을 강조한 o1 모델 등이 있으며, 이 밖에도 Google의 Gemini, Anthropic의 Claude, Meta의 LLaMA, Alibaba의 Qwen, LG의 EXAONE 등 다양한 모델이 개발되어 활용되고 있다.

거대 언어 모델의 발달로 텍스트 생성을 넘어 글의 맥락을 이해하고, 복잡한 추론, 코드 생성, 수학적 문제 해결 등 인간의 영역이라고 생각되던 고차원적인 인지 활동에도 활용되고 있다. 최근의 연구들은 모델들이 과학적 문제 해결 과정에서도 상당한 수준의 수행 능력을 보이는 것으로 보고되고 있다 [1]. 그러나 이러한 능력이 실제 물리적 원리에 대한 깊은 이해에서 비롯된 것인지, 아니면 방대한 학습 데이터에 포함된 패턴을 단순히 재구성한 것인지에 대해서는 여전히 의문이 있다. 즉, 거대 언어 모델이 단순한 확률론에 기반한 답변이 아닌 복잡한 물리적 현상을 어떻게 개념화하고, 수리적으로 해결하는지는 아직 충분히 검증되지 않았다.

자연 현상에 대한 근본적인 이해를 바탕으로 법칙을 적용하고 현상을 예측하는 물리학 문제는 거대 언어 모델의 적용 가능성을 평가하는 데에 있어서 중요한 과제이다 [3, 4]. 왜냐하면, 물리학은 문제 해결 과정에서 주어진 상황을 분석하여 적절한 물리 법칙에 적용한 후, 수학적 계산을 통해 문제를 해결하는 복잡한 인지 과정을 포함하고 있기 때문이다. 그리고 단순한 공식 암기나 지식의 인출을 넘어서 복잡한 개념의 이해, 다단계 추론, 수학적 능력, 공간적 사고 등을 함께 요구한다. 물리 문제 해결 과정은 단순히

공식에 숫자를 대입하는 행위가 아니다. 문제의 텍스트와 시각적 정보를 모델링해서 물리 법칙에 적용하고 이를 수학적으로 전개해야 하며, 도출된 답을 문제의 조건과 물리적 의미에 비추어 타당한지 검토하는 과정도 필요하다 [5, 6]. 특히 물리학은 원리나 법칙을 다양한 상황과 맥락에 맞게 유연하게 적용할 수 있어야 한다. 따라서 거대 언어 모델이 이러한 인지 과정을 거쳐 물리학 문제를 성공적으로 해결할 수 있는지를 파악하는 것은, 인공지능이 사람의 인지 능력의 핵심이라 할 수 있는 원리나 법칙을 실생활 맥락에서 유연하게 적용하고 문제 해결하는 능력에 얼마나 도달했는지 가늠할 수 있는 중요한 척도가 된다 [7].

물리 교육 분야에서 거대 언어 모델은 학생이나 교사에게 새로운 가능성을 제시하는 혁신적인 도구로 여겨지고 있는데, 거대 언어 모델을 활용한 물리학 학습 및 문제 해결 연구도 최근 활발히 진행되고 있다 [8-11]. 거대 언어 모델은 학생의 답안을 채점하거나 평가하는 데에 활용할 수 있고 [12-16], 지능형 튜터링 시스템의 형태로 학생들에게 개별화된 피드백을 실시간으로 제공하거나 [17, 18], 교사의 수업 설계 및 평가 문항 개발을 지원하는 데 유용하게 활용될 수 있다 [19, 20]. 또한, 자동화된 피드백 생성 연구에서는 거대 언어 모델이 생성한 피드백이 상세하거나 유용하다는 평가를 받기도 한다 [21, 22]. 특히 인공지능을 활용하여 학생들의 응답 데이터를 즉각적으로 분석하고, 오답지를 선택한 학생들에게 관련된 학습 과제를 제시하는, 이른바 적응형의 학습 경로를 제공하는 것은 매우 중요한 응용 분야이다 [21]. 그러나 이러한 응용이 실제 교육 현장에서 활용되기 위해서는 거대 언어 모델이 생성하는 텍스트나 정보가 풍부한 것도 중요하지만, 물리적으로 타당하고 정확한 정보를 산출할 수 있을 정도의 성능을 갖추고 있음이 검증되어야 한다.

물리 교육에서 거대 언어 모델의 성능을 평가하려는 연구는 모델 생성 초기부터 활발히 진행됐다 [23]. 우선 기존에 학생들의 개념을 조사하기 위해 개발된 검사 도구를 활용하여 성능을 분석한 연구들이 있는데, 힘 개념 검사(FCI), 기초 전자기학 평가(BEMA), 역학 그래프 이해도 검사(TUG-K)와 같은 표준화된 개념 검사지를 활용하여 거대 언어 모델의 물리학 개념 이해도를 측정하였다 [24, 25]. 연구 결과에 따르면, GPT-4와 같은 최신 모델은 FCI 등에서 전문가 수준에 근접하는 높은 정확도를 기록하기도 하지만, 여전히 물리적 상황에 대한 공간적 추론이나 복잡한 다단계 문제 해결에서는 한계를 보였다. 미국의 학업성취도 평가(NAEP)에 대한 연구에서도 GPT-4가 대부분의 학생들보다 높은 성능을 보이고, 과제의 인지적 수준에 따라 크게 차이도 없는 것으로 보고되었다 [7]. 물리 올림피아드 문제에서도 인간 참가자보다 높은 성능을 보이기도 하였다 [6].

한편, 물리 문항 풀이에 대한 거대 언어 모델의 능력을 평가하기 위한 다양한 벤치마크를 활용한 연구가 있다 [26–28]. 기존의 벤치마크가 주로 단순한 지식 기반 문제나 기초적인 수학 계산에 초점을 두었으나, 최근에는 보다 복잡하고 실제적인 물리학 문제를 포함한 벤치마크들이 연구되고 있다. OpenAI의 기술 보고서에 따르면, GPT-4는 AP Physics 2 시험에서 상위권 성적인 4점(66th–84th)을 기록하며 이전 모델인 GPT-3.5보다 비약적인 발전을 보였다 [29]. Zhai (2025)는 ChatGPT와 GPT-4가 대부분의 과학 과제에서 학습자보다 높은 성과를 보였음을 보고하였다 [7]. 특히 대학 입시 수준의 MMLU(Massive Multitask Language Understanding)-Physics 벤치마크에서 최신 모델들은 80% 이상의 정확도를 기록하기도 하였다. 그러나 Wang *et al.*의 연구에 따르면, GPT-4는 조건이 완벽한 문제에는 강한 성능을 보이지만, 정보가 부족하거나 물리적 상황이 명시적이지 않은 상황의 문항에서는 정답률이 8.3%로 급락하는 취약성을 보였다 [30]. Loubet *et al.*가 열역학 문제를 가지고 여러 모델을 검증한 결과에 의하면, 거대 언어 모델은 문제와 맞지 않는 잘못된 가정을 하거나, 산술 계산 및 부호 적용에서 오류를 범하고, 부적절한 방정식을 사용하며 맥락을 유지하지 못해 해결 방향을 잃기도 한다. 또한 불필요하게 장황한 설명으로 핵심을 흐리거나 의미 있는 해결책을 제시하지 못하는 한계가 발생하기도 한다 [26]. 그리고 문제의 내용에서 맥락을 잘못 파악하고, 가정을 인지하지 못하거나 핵심 개념을 오해하여 잘못된 공식을 사용하는 사례가 보고되기도 하였다 [4,31].

앞서 강조한 것처럼 거대 언어 모델이 어떠한 지점에서 취약한지를 밝혀내는 것은 안전하고 신뢰할 수 있는 교육용 AI 시스템을 구축하기 위한 선결 조건이다. 그러나 현재 거대 언어 모델에 대한 물리학 성능 평가는 주로 영어권 데이터를 중심으로 이루어져 한국어 환경에서의 체계적인 평가는 상대적으로 부족하였다. 최근 연구에 따르면, GPT-4o와 같은 고성능 모델조차 언어의 종류에 따른 성능의 편차가 크며, 특히 비서구권 언어에서 물리 추론 능력이 현저히 저하되는 언어 격차 문제가 나타나고 있다 [32]. 한국어는 한자어와 외래어를 혼용하여 사용하는 특별한 물리 용어 체계를 가지고 있으므로 문항 해석에 있어서 복잡하고 언어적 정교함이 추가적으로 필요하다. 따라서 한국어로 된 물리 문항에 대한 거대 언어 모델의 언어 이해도와 해결 능력을 평가하는 것은 한국의 물리 교육 환경에서 거대 언어 모델을 도입하고 활용하기 위해 선행되어야 할 과제이며, 해당 모델에 대한 교육적 활용 가능성을 판단하는 중요한 지표가 된다.

언어적 특수성뿐만 아니라, 물리 문항에는 다이어그램이나 그래프와 같은 시각 자료가 많이 포함되어 있다. 초기

벤치마크가 텍스트만을 입력으로 사용하거나 시각 정보를 텍스트로 변환하여 입력한 경우가 많지만 [6,24], 실제 학생들은 그림, 그래프, 도표가 포함된 문항을 시각적으로 해석하면서 문제를 해결한다. 따라서 물리 문항에 대한 거대 언어 모델의 성능을 평가할 때는 이러한 시각 정보를 함께 처리하는 능력까지 살펴보아야 한다.

본 연구는 한국어 물리 선다형 문제를 중심으로, 특히 그림이 포함된 문항에 대한 거대 언어 모델의 해석 및 추론 능력을 평가함으로써 멀티모달 인지 과정에서 나타나는 모델의 가능성과 한계를 살펴보고자 한다. 거대 언어 모델은 대부분 신경망에 기반한 구조로 되어 있어 내부적인 작동 방식을 알 수 없으므로 경험적인 검증만이 가능하다. 이를 위해 설정한 구체적인 연구 문제는 다음과 같다.

첫째, 한국어로 구성된 고등학교 물리학 선다형 문제에서 거대 언어 모델의 성능은 어떠한가? 다양한 최신 거대 언어 모델 간의 한국어 고등학교 물리 선다형 문항 정답률 및 풀이 정확도에는 어떠한 차이가 나타나는지 분석하고자 한다.

둘째, 문제에 포함된 다이어그램이나 그래프와 같은 멀티모달 정보가 거대 언어 모델의 성능에 어떤 영향을 미치는가? 물리 문항에는 다양한 그림(그래프, 도표 등)이 포함된 경우가 많으므로 이러한 요소의 포함 여부와 복잡성이 문제 해결에 미치는 영향을 분석해 보고자 한다. 이 과정에서 한국어 물리 문항 풀이 과정에서 거대 언어 모델의 주요 오류 유형은 무엇이며, 어떠한 인지적 한계를 지니는지도 살펴보고자 한다.

이와 같은 연구를 통해 거대 언어 모델의 물리학 문제 해결 능력에 대한 더 깊은 이해를 얻을 수 있을 것으로 기대한다. 또한 향후 학교 교육 현장에서 거대 언어 모델을 활용한 지능형 튜터, 학습 동반자 등과 같은 학습 도구 개발이나 평가 시스템 구축을 위한 중요한 기초 자료를 제공할 수 있을 것이다.

## II. 연구 방법

본 연구에서는 2026학년도 대학수학능력시험(이하 수능) 물리학I 과목의 20개 문항을 연구 대상으로 하여, 최신 거대 언어 모델이 한국어 텍스트와 시각 정보를 동시에 처리해야 하는 멀티모달 환경에서 물리학 문항에 대한 해결 능력과 한계를 분석하였다. 수능은 고등학교 교육과정의 내용을 바탕으로 대학 교육에 필요한 논리적 사고력과 문제 해결 능력을 측정하는 국가 수준의 표준화된 평가이다. 특히 물리학I은 단순한 지식의 암기 여부를 확인하는 수준을 넘어, 물리적 현상을 과학적 원리에 기반하여 통합적으로



이해하고 이를 새로운 상황에 적용할 수 있는지를 평가하는 데 목적을 둔다. 역학, 전자기, 빛과 파동, 현대물리 등 물리학의 주요 영역을 모두 포괄하고 있으며, 물리학 관련 개념 이해를 평가하는 문항부터 복합적인 물리 상황에 대한 분석과 많은 계산을 요구하는 문항까지 다양하게 구성되어 있다. 따라서 거대 언어 모델의 물리학 문제 해결 성능을 평가하기에는 적절한 자료라 할 수 있다. 더불어 현재 고등학생들이 실제 비슷한 유형의 문항으로 물리학을 학습하고 있기 때문에, 이에 대한 성능을 분석하는 것은 향후 고등학교 수준에서 모델의 활용 가능성을 검토하는 데 탐색적 자료로 활용될 수 있다.

연구 대상 거대 언어 모델은 가장 보편적이며 범용형, 추론형, 경량형, 고성능형을 고르게 포함할 수 있도록 7종의 모델(gpt-4.1, o3, o4-mini, gpt-5.2, gemini-2.5-flash, gemini-3-pro-preview, claude-opus-4.6)을 선정하였다. 2026학년도 수능(2025년 11월 시행) 이후인 2025년 12월부터 2026년 2월 사이에 연구가 수행되었는데, 가장 보편적이고 이용률이 높은 거대 언어 모델을 대상으로 하기 위해 OpenAI, Google, Anthropic 계열을 선정하고 연구 수행 시점 기준으로 최신 API 버전을 기준으로 하였다. 우선 가장 보편적인 OpenAI의 모델은 다양한 버전을 대상으로 하였는데, gpt-4.1은 별도의 추론 단계를 두지 않지만, 텍스트 생성에 안정성을 가진 범용 모델이며, o3는 최종 답변을 생성하기 전 모델 내부적으로 다단계의 사고 과정을 거치는 추론 모델로 복잡한 물리 법칙 적용이나 연역적 증명 등 논리적 사고가 필요한 문제 해결에 특화된 모델이다. o4-mini는 o시리즈의 논리적 추론 구조를 따르지만 모델의 크기를 경량화한 버전이며, gpt-5.2는 연구 수행 시점 기준인 2025년말 기준으로 사용 가능한 최신 계열 추론 모델이다. Google 계열의 gemini-2.5-flash는 대용량 입력과 빠른 응답에 강점을 지닌 범용 모델이며, gemini-3-pro-preview로 복잡한 정보를 처리하는 추론 모델이다. Anthropic 계열의 claude-opus-4.6은 인간 수준의 복잡한 논리와 추론 능력을 갖춘 모델로 평가된다. 이와 같이 본 연구는 연산 효율성을 중시하는 경량 모델부터 심층 추론에 특화된 모델까지 다양하게 연구 대상을 선정하였다.

평가 대상인 거대 언어 모델에 수능 물리학 문항을 각각 텍스트, 이미지, 텍스트와 이미지가 결합한 세 가지 조건으로 입력하고, 입력 방식에 따라 나타나는 문제 해결 능력을 비교하였다. 먼저 텍스트 입력 조건에서는 문항에 포함된 모든 그림이나 표의 내용을 모두 텍스트로 변환한 뒤, 글자 형태의 지문과 선택지만을 프롬프트로 제공하였다. 수능 물리학 문항은 ‘그림과 같이’나 ‘표와 같이’와 같은 표현을 사용하여 문제 해결에 필요한 정보가 텍스트뿐만 아니라

그림이나 표에 담겨 있는 경우가 많다. 이에 따라 연구에서는 그림이나 표의 내용을 연구자가 구체적으로 텍스트로 전환하고, 현직 물리 교사 2명의 검토를 거쳐 입력하였다. 이미지 입력 조건에서는 문항 전체를 하나의 이미지파일 형태로만 입력하였다. 이 경우 거대 언어 모델이 자체적으로 문자 인식 등을 통해 기호를 포함한 텍스트를 인식하고, 기하학적 도식이나 그림으로부터 물리적 상황을 인지한 후 변인을 추출하여 문항을 해결하도록 하였다. 마지막으로 텍스트+이미지 입력 조건에서는 문항의 본문 텍스트, 그림이나 표를 설명한 텍스트, 그리고 문항 전체 이미지를 동시에 입력하였다.

데이터 수집은 일관성과 재현 가능성을 높이기 위해 Python 기반의 자동화된 API(application programming interface) 파이프라인을 이용하였다. 모든 모델에 동일한 시스템 프롬프트를 적용하여 ‘수능 물리 문항 풀이 전문가’의 역할을 부여하였고, 전체 풀이 과정과 1~5번 중 선택 다형의 최종 정답을 JSON 형식으로만 반환하도록 응답 스키마를 통제하였다. 또한, 각 모델의 심층 추론 성능을 극대화하기 위해 Gemini 계열 모델은 ‘thinking\_level’을 ‘high’로, OpenAI의 추론형 모델은 ‘reasoning effort’를 ‘high’로 설정하였다. 그리고 추론 모델이 아닌 gpt-4.1에는 ‘temperature=0’을 적용하여 무작위성을 최소화하였다. Anthropic 계열도 추론의 정도는 ‘effort’를 ‘high’로 설정하였다. 동일 문항의 반복 실행은 각 시행을 독립 호출로 실시하였다.

연구에서는 거대 언어 모델의 문제 해결 능력을 전반적인 성능과 세부적인 논리 일관성 측면으로 구분하여 평가하였다. 거대 언어 모델은 특성상 확률적 생성 방식으로 응답을 산출하므로, 동일한 질문에 대해서도 다른 답변을 할 가능성이 있다. 따라서 모델의 성능을 평가할 때는 정답률뿐만 아니라 응답의 일관성을 살피는 것도 중요하다.

전반적인 성능 평가는 2026학년도 수능 물리학I 전체 20개 문항 [33]을 7종의 거대 언어 모델이 각각 문항 풀이하도록 하였다. 이때 각 모델의 입력 조건은 텍스트 단독, 이미지 단독, 텍스트와 이미지 결합의 세 가지로 구분하였다. 세부적인 일관성 평가에서는 거대 언어 모델을 사용하는 데에는 토큰당 비용이 발생하기 때문에 모든 문항을 대상으로 하거나 반복 횟수를 크게 늘리기에는 연구에 한계가 있었다. 따라서 전체 문항 중 기본 개념 중심 문항, 고난도 공간 기하 추론 문항, 그래프 해석 문항, 복합적인 역학 시스템 문항을 대표하는 4개 문항(2번, 11번, 14번, 19번)을 선정하여 반복 수행을 통해 논리적 일관성을 검토하였다. 각 문항에 대해 세 가지 입력 조건별로 모델마다 10회씩 독립적으로 풀이를 실시하였으며, 이를 바탕으로 정답 도출의




Fig. 1. Model performance benchmark: All items.

일관성을 검토하였다. 아울러 오답이 발생한 경우에는 모델이 제시한 풀이 과정을 검토하여 오답의 원인과 특성을 분석하였다.

다만 본 연구가 연구 대상 문항 수와 반복 시행에 제한이 있고, 연구 수행 시점에 접근 가능했던 모델들로 한정되므로, 버전 변화에 따라 결과가 달라질 수 있는 한계가 있을 수 있다.

### III. 연구 결과

#### 1. 거대 언어 모델의 전반적인 물리학 문항 해결 능력

Figure 1은 20개 문항에 대한 거대 언어 모델 7종의 세 가지 입력 조건(Text, Image, Text+Image)하에서 평균 정답률을 나타낸 것으로, 각 모델별 성능과 입력 조건에 따른 차이를 비교할 수 있다. 그리고 전체 평균 정답률만으로는 각 모델의 문항별 특성을 충분히 파악하기 어려우므로 개별 문항에 대해 7개 모델이 어떠한 성능을 보였는지를 함께 살펴 어떠한 문항에서 거대 언어 모델이 장점을 보이는지를 분석해 보고자 하였다. Table 1은 수능 물리학I 각 문항에서 7개의 모델 중 정답을 맞힌 모델의 수를 나타낸 것이며, Table 2는 정답 여부(정답=1, 오답=0)를 종속변수로 하여 모델, 입력 조건(모드), 문항의 효과를 검정한 결과이다. 개별 문항의 난이도 편차로 인한 분산을 통제하기 위해 문항을 통제 변인으로 하고 이항 로지스틱 회귀 모형(Binomial GLM)으로 우도비 검정(Likelihood Ratio Test)을 실시하였다.

Figure 1에 따르면, gpt-4.1은 모든 입력 조건에서 전체 모델 중 가장 낮은 정답률을 보였다. 정답률이 텍스트 입력이 50%, 이미지 입력이 30%, 텍스트와 이미지 동시 입력이

Table 1. Number of models with correct answers by item.

| Problem ID | Text    | Image  | Text+Image |
|------------|---------|--------|------------|
| 1          | 7       | 7      | 7          |
| 2          | 6       | 5      | 7          |
| 3          | 7       | 5      | 7          |
| 4          | 7       | 1      | 7          |
| 5          | 5       | 7      | 6          |
| 6          | 5       | 0      | 4          |
| 7          | 7       | 4      | 6          |
| 8          | 7       | 6      | 7          |
| 9          | 7       | 7      | 6          |
| 10         | 5       | 5      | 4          |
| 11         | 1       | 3      | 1          |
| 12         | 7       | 7      | 7          |
| 13         | 3       | 4      | 6          |
| 14         | 7       | 5      | 7          |
| 15         | 6       | 4      | 7          |
| 16         | 6       | 7      | 7          |
| 17         | 5       | 2      | 6          |
| 18         | 5       | 4      | 6          |
| 19         | 7       | 6      | 7          |
| 20         | 4       | 0      | 3          |
| Overall    | 114/140 | 89/140 | 118/140    |

60%이었다. gpt-4.1은 비교적 구형 모델로 복잡한 논리 전개나 시각적 도표 해석을 해야 하는 문항에서 낮은 성능을 보였다 [1]. 특히 이미지 입력 조건에서 정답률이 30%로 매우 낮아 물리학 문항의 이미지에서 문제 해결에 필요한 정보를 충분히 추출하지 못했음을 나타낸다. 다만 텍스트와 함께 이미지 정보를 동시에 입력하면 정답률이 상승하여, 시각 정보가 언어 정보와 결합할 때 성능이 일부 보완될 수

Table 2. Likelihood ratio test (LRT) results for GLM-based binomial logistic regression.

| Effect              | LR $\chi^2$ | df | p-value   |
|---------------------|-------------|----|-----------|
| Model               | 74.357      | 6  | < .001*** |
| Mode                | 34.267      | 2  | < .001*** |
| Problem ID          | 146.654     | 19 | < .001*** |
| Model $\times$ Mode | 4.163       | 12 | 0.980     |

있음을 알 수 있다.

한편, gpt-4.1에 비해 개선된 추론 모델이거나 이를 경량화한 모델인 o3, o4-mini, 그리고 gemini-2.5-flash는 텍스트 입력 조건에서 공통적으로 80%의 정답률을 보여, 거대 언어 모델 중 추론 모델이 물리학 문제 해결에서 높은 성능을 보임을 알 수 있다 [6]. 그러나 이미지 입력 조건에서는 정답률이 o3가 50%, o4-mini가 55%로 텍스트 입력에 비해 여전히 정답률이 낮아 시각 정보 처리 능력에서 낮은 성능을 보였다.

반면 gemini-2.5-flash는 이미지 입력 조건에서도 약 70%의 정답률을 보였으며, 2025년말 기준으로 최신 모델인 gpt-5.2와 gemini-3-pro-preview는 정답률이 텍스트 입력에서 95%, 이미지 입력에서 85%로, 양쪽 조건 모두에서 매우 높은 성능을 보였다. 특히 타 모델들이 이미지 입력 조건에서 30~70% 수준의 비교적 낮은 정답률을 보이지만, gpt-5.2와 gemini-3-pro-preview는 이미지 입력 조건만으로도 85%의 높은 정답률을 보였다. 이들 모델이 시각 정보를 파악하고 해석하는 능력에서도 상위 수준의 성능을 보임을 알 수 있다. claude-opus-4-6 역시 텍스트 입력에서 90%, 이미지 입력에서 70%의 높은 정답률을 보였으며, 특히 텍스트와 이미지를 동시에 입력했을 때는 gpt-5.2와 동일한 수준인 95%의 정답률을 나타냈다. 다만 이미지 입력 조건에서의 성능이 중간정도 수준이었다. 그리고 전체 문항에 대한 정답률을 보면 텍스트와 이미지를 함께 입력한 조건에서 전반적으로 더 높은 성능과 안정성을 보였다. 멀티모달 정보가 상호 보완적으로 작용함으로써 상황에 대한 이해와 추론 과정이 더 안정적으로 이루어질 수 있다.

이러한 특성은 Table 1에서도 확인할 수 있다. 전체 정답 수(최대 140개)를 살펴보면, 앞서 제시한 결과와 같이 멀티모달에 따른 성능의 차이가 났다. 이미지 입력 조건에서의 전체 정답 수는 89/140으로 가장 낮았는데, 이는 텍스트 없이 시각적 그림, 도표, 그리고 이미지 형태의 수식만으로 정보를 해석하는 것이 여전히 많은 모델에서 충분히 안정적이지 않음을 알 수 있다. 반면 텍스트 입력 조건에서는 전체 정답 수가 114/140으로 크게 증가하였다. 언어 모델의 특성상 자연어 처리와 논리적 추론이 텍스트 조건에서 가장

안정적임을 반영한 결과라 할 수 있다. 또한 텍스트와 이미지를 함께 제공한 조건에서는 전체 정답 수가 118/140으로 가장 높았다. Table 2를 보면, 로지스틱 회귀 기반 분산분석 결과 정답률은 모델, 모드, 문항에 따라 모두 통계적으로 유의하게 달라졌다. 반면에 모델과 모드의 상호작용은 유의하지 않아 입력 조건에 따른 차이가 특정 모델에서만 다르게 나타나지는 않았다.


그러나 Fig. 1을 보면 두 gemini 모델에서 다소 특이한 경향을 확인할 수 있다. 텍스트 입력보다 텍스트와 이미지를 함께 입력했을 때 정답률이 gemini-2.5-flash는 80%에서 75%로, gemini-3-pro-preview는 95%에서 90%로 오히려 낮아지는 경향을 보였다. 이러한 결과는 문제 해결에 필요한 핵심 정보가 텍스트만으로도 충분히 제공되었음에도, 추가된 이미지 정보가 모델의 추론 과정에서 오히려 간섭 요인으로 작용했을 가능성이 있다. 즉, 연구자가 제공한 이미지 관련 정보가 텍스트 정보와 결합되는 과정에서 논리적 충돌이나 해석상의 혼선을 일으켰을 수 있다. 이것은 실제 문제 풀이 과정에서 인간이 임의로 그림을 설명하여 제공하는 것의 위험성을 알려준다. 텍스트와 이미지를 동시에 입력할 때, 그림을 설명하기 위해 인간이 주관적으로 추가한 텍스트 정보가 오히려 논리적 충돌을 일으켜 정답률을 떨어뜨리기도 하였는데, 이는 과도하거나 불필요한 맥락이 문제 해결에 방해를 줄 수 있다는 기존의 지적 [34]과 맥을 같이 한다.

또한, Table 1을 살펴보면, 문항별 성능은 몇 가지 공통적인 경향에 따라 유형화할 수 있다. 예를 들면, 1번, 12번 문항은 모든 입력 조건에서 안정적인 성능을 보이며, 3번, 8번, 14번, 19번 문항 역시 텍스트 입력 조건에서는 모든 모델이 정답을 산출하였다. 이러한 문항들의 공통된 특징을 보면 물리학 개념에 대한 이해를 중심으로 해결할 수 있는 문항이었다. 이에 반해 4번, 6번, 20번 문항은 이미지 입력 조건에서 특히 낮은 성능을 보였다. 이들 문항은 그림에 대한 해석이 문항 해결에 핵심이거나, 시각 정보만으로는 조건을 완전히 복원하기 어려운 유형이다. 그리고 11번 문항은 전반적으로 가장 정답률이 낮은 문항인데, 단순 계산 문제가 아니라 공간적 추론과 개념 결합이 동시에 요구되기 때문으로 보인다. 이에 대한 자세한 논의는 다음 절의 주요 문항별 풀이 및 주요 오류 요인 분석에서 살펴볼 것이다.

수식 중심의 문항에서는 텍스트 입력 모드에서 비교적 높은 성능이 나타나지만 광학, 경사면 구조, 복합 경로처럼 시각적 구조의 해석이 핵심이 되는 문항에서는 시각 정보를 얼마나 정확하게 이해하느냐가 정답을 좌우하는 중요한 요인으로 작용하였다. 다만 일부 모델은 이미지 정보만으로 인간의 문제 해결 과정과 유사한 추론 양상을 보일 만큼 높은 성능이 나타났다.



2. 그림과 같이 균일한 자기장에 의해 자기화된 상태에 있는 크기와 모양이 같은 물체 A, B, C 중 2개를 꺼내어 하나는 수평면에 놓고 다른 하나는 높이  $h_0$ 에서 가만히 놓아 떨어뜨린다. 표는 두 물체가 닿을 때까지 걸린 시간  $T$ 를 나타낸 것이다. A, B, C는 강자성체, 상자성체, 반자성체를 순서 없이 나타낸 것이고, 균일한 자기장 영역에서 B와 C가 자기화된 방향은 서로 같다.



A, B, C로 옳은 것은?

- |   | A    | B    | C    |
|---|------|------|------|
| ① | 강자성체 | 상자성체 | 반자성체 |
| ② | 강자성체 | 반자성체 | 상자성체 |
| ③ | 상자성체 | 강자성체 | 반자성체 |
| ④ | 반자성체 | 강자성체 | 상자성체 |
| ⑤ | 반자성체 | 상자성체 | 강자성체 |

Fig. 2. Content of item 2 [33].




Fig. 3. (Color online) Performance results for item 2 by model and mode.

## 2. 주요 문항별 풀이 및 오류 요인 분석

앞 절에서는 대표적인 모델들의 전반적인 특징과 전체적인 성능을 살펴보았는데, 전체 20개 문항을 분석한 결과에 따르면 문항의 특성에 따라 몇 가지 유형으로 구분할 수 있었다. 이에 따라 본 절에서는 그중 대표적인 4개 문항(2번, 11번, 14번, 19번)을 중심으로 모델의 논리적 일관성과 구체적인 풀이 양상 및 주요 오류 원인을 분석하였다. Figures 3, 5, 7, 9는 각 모델에 대해 세 가지 입력 조건을 적용하고, 각 조건에서 10회씩 반복 수행하였을 때의 정답률을 나타낸 것이다.

먼저 Fig. 2에 제시된 2번 문항은 균일한 자기장 영역에서 강자성체, 상자성체, 반자성체를 자기화하였을 때, 물체 사이에 작용하는 힘을 바탕으로 각 물체의 자성을 추론하는 문항이다. 이 문항에 실험 상황을 나타내는 비교적 단순한

모식도가 포함되어 있으나, 문제 해결의 결정적 단서는 시각적 요소보다 텍스트로 제시된 문항 지문과 표의 조건에 있다. 즉, ‘균일한 자기장 영역에서 B와 C가 자기화된 방향은 서로 같다’는 명제와 두 물체가 닿을 때까지 걸린 시간  $T$ 의 대소 관계를 함께 해석함으로써 각 물질의 자성을 정해야 한다.


2번 문항에 대한 각 모델별 정답률은 Fig. 3과 같다. 문항에서 그림을 제외하고 텍스트 지문만을 입력한 조건에서는 gpt-4.1을 포함한 대부분의 모델이 90–100%의 높은 정답률을 보였다. gpt-4.1은 100%, o3는 90%, o4-mini는 100%, gpt-5.2는 100%, gemini-2.5-flash, gemini-3-pro-preview, 그리고 claude-opus-4-6도 모두 100%이었다. 이러한 결과는 물리적 상황이 텍스트로 명확히 환원하여 입력되면, 거대 언어 모델은 자연어 기반의 논리 전개 및 연역적 추론 능력이 비교적 안정적임을 알 수 있다.

한편, o3가 한 차례 오답을 보였는데, A가 반자성체이고 B, C가 강자성체 또는 상자성체라는 점까지는 올바르게 추론하였으나, 반자성체와 자성체가 마주할 때 척력이 작용하여 낙하 시간이 지연된다는 적절한 해석 대신, 자화 방향이 반대라는 점만을 근거로 인력이 작용한다고 잘못 추론하였다. 이는 모델이 물리적 상황 전체를 일관되게 해석하기보다, ‘자화 방향이 반대이면 인력이 작용한다’는 식의 부정확한 개념 연결을 부분적으로 적용할 가능성이 있다.

그러나 이미지만 입력한 조건에서는 모델 세대에 따라 성능의 편차가 컸다. gpt-4.1은 20%의 저조한 정답률을 보였는데, 이는 초기 시각 인코더 모델이 이미지 형태의 문서에서 조건이나 표의 수치 정보를 정확하게 추출하고 이를 구조화된 정보로 전환하는 데 한계가 있음을 나타낸다. 다른 모델인 o3는 70%, o4-mini는 80%, claude-opus-4-6은 90%의 정답률을 보여 성능이 향상되지만, 여전히 텍스트 입력 조건보다는 정답률이 낮다. 오답 사례를 보면, 선행 연구 [26,28]에서도 지적된 것과 유사하게 문제에 제시되지 않는 조건인 ‘B와 C는 자화 방향이 서로 반대’라며 조건을 임의로 추가하거나 강자성체가 인력이 강해서 빨리 떨어진다고 해석하는 등 물리 개념을 잘못 적용하는 경우가 많았다. 그리고 claude-opus-4-6에서는 ‘A(반자성체)는 B, C와 반대 방향으로 자기화되어 있으므로, A를 떨어뜨리면 B, C와 인력이 작용’한다고 잘못된 물리적 개념을 적용하였다.

이에 비해 gpt-5.2, gemini-2.5-flash, gemini-3-pro-preview는 이미지 입력 조건에서도 100%의 정답률을 보였다. 최신 멀티모달 모델이 도형, 표, 조건 배열 등을 시각적으로 해석하고 이를 물리 개념과 통합하는 능력이 크게 개선되었음을 알 수 있다. 특히 이 문항은 균일한 자기장, 자화 방향, 낙하 시간 비교라는 복합 요소를 포함하고 있어 단순 시각 인식이 아니라 물리적 상황을 재구성해야 하는데,

11. 그림과 같이 단색광 P가 공기에서 매질 A에 입사각  $\theta_1$ 로 입사한다. 매질 B와 공기의 경계면에서 P의 일부는 굴절각  $\theta_2$ 로 굴절하여 진행하고 일부는 반사한 후 매질 C와 공기의 경계면에서 전반사한다.  $\theta_2 > \theta_1$ 이다.



이에 대한 설명으로 옳은 것만을 <보기>에서 있는 대로 고른 것은?

- <보 기>
- ㄱ. 굴절률은 A가 B보다 크다.
  - ㄴ. P의 속력은 B에서 C에서보다 크다.
  - ㄷ. P가 B와 공기의 경계면에서 전반사하게 하려면  $\theta_1$ 를 증가시켜야 한다.

- ① ㄱ    ② ㄴ    ③ ㄷ    ④ ㄱ, ㄷ    ⑤ ㄴ, ㄷ

Fig. 4. Content of item 11 [33].




Fig. 5. (Color online) Performance results for item 11 by model and mode.

초기 모델은 이미지 속에서 표와 조건을 충분히 구조화하지 못해 오답률이 높았던 반면, 최신 모델은 높은 정답률을 보였다.

Figure 4에 제시된 11번 문항은 단색광이 공기과 세 가지 매질(A, B, C)의 경계면을 통과할 때 굴절과 전반사 현상을 해석하고, 스넬의 법칙을 적용하여 각 매질의 굴절률과 빛의 속력을 비교하는 고난도 광학 문제이다. 이 문항은 문제 해결에 필요한 정보가 텍스트가 아니라 기하학적인 광경로로 제시될 때, 거대 언어 모델이 이를 얼마나 정확히 해석하여 문제를 해결할 수 있는지 평가할 수 있다. 매질의 기하학적인 형태, 법선의 위치, 광선의 굴절 정도 등은 이미지를 통한 공간적 해석 없이는 문제를 해결할 수 없는 형태의 문항으로, 이 문항에서는 시각 정보 해석 및 처리 능력이 성능을 결정하는 핵심 요인이다. 즉, 모델의 시각 정보 의존성과 공간 기하학적 추론 능력을 평가할 수 있는 문항이다.

11번 문항에 대한 각 모델별 정답률은 Fig. 5와 같다. 텍스트 입력 조건에서는 정답률이 gpt-4.1, o3, gpt-5.2, claude-opus-4-6은 0%, o4-mini, gemini-2.5-flash는 10%,

gemini-3-pro-preview도 20%로 매우 낮은 정답률을 보였다. 이는 텍스트 입력 시 주어진 그림을 최대한 텍스트로 표현하여 입력하였으나 이것으로는 문항을 해결할 수 없음을 알 수 있다. 즉 이와 같은 문항은 그림에 담긴 핵심 조건을 텍스트만으로 온전히 변환하여 제시할 수 없다. 특히, 인간이 그림을 해석하는 방식과 거대 언어 모델이 문제 해결에 필요한 정보들을 처리하는 방식은 동일하지 않을 수 있으므로, 그림의 구조와 관계를 텍스트로 완전히 환원하는 데에는 근본적인 한계가 있음을 알 수 있다.

또한, 이미지 입력 조건에서는 gpt-4.1, o3, o4-mini, claude-opus-4-6가 정답률이 0~20%로, 이미지에서 선과 각도의 비례 등을 인식하고 물리 법칙에 대입하는 기하학적 공간 지각력이 부족하여 거의 문제를 해결하지 못하였다. 반면 gpt-5.2는 정답률이 100%로, 이미지를 단순한 그림이 아니라 기하학적 구조와 물리적 관계를 추출하여 문제 해결에 활용할 수 있음을 알 수 있다. 또한 gemini-2.5-flash는 60%, gemini-3-pro-preview는 70%의 정답률을 보여 비교적 높은 수준의 시각적 문제 해결 능력을 보였다. 이러한 높은 성능을 보인 최신 모델들의 풀이 과정을 분석해 보면 그림 속의 광선 경로, 입사각과 굴절각의 관계, 전반사 조건 등을 비교적 정확히 파악해 냈다. 최신의 모델들은 그림을 단순히 시각적으로 인식하는 수준이 아닌 물리적 상황으로 재해석하고 법칙과 연결하는 능력이 크게 향상되었음을 알 수 있다.

오류 사례를 분석해 보면, gpt-4.1은 시각 정보의 제공 여부와 무관하게 2차원적인 60° 췌기형 프리즘 구조를 제대로 인식하지 못했다. 경계면이 기울어져 있다는 조건을 빠뜨린 채, 빛이 1차원 평행판을 통과하는 상황으로 단순화하여 해석하거나 잘못된 공식( $n_A \sin \theta_1 = n_B \sin \theta_2$ )을 기계적으로 적용하였다. 또한, 'B에서는 굴절, C에서는 전반사'라는 명시적인 텍스트 단서조차 문제 해결의 단서로 활용하지 못하였다. 전반적으로 구형 모델(gpt-4.1)은 도형의 기하학적 구조를 무시하는 오류를 보였고, gemini 모델들은 기하학적 관계를 추적하려 시도했으나 변수 간의 증감 관계에서 혼동을 겪는 경우가 있었다. claude-opus-4-6은 문제 텍스트에 있는 '60°'라는 키워드만 보고, 독립된 60° 정삼각형 프리즘의 꼭지각 공식( $A = r_1 + r_2 \rightarrow i_2 = 60 - r_1$ )을 두 번 연속으로 적용하다가 보기 ㄷ을 거꾸로 해석하여 4번이나 5번이라고 답하는 경우가 대부분이었다.

텍스트와 이미지를 동시에 입력한 조건에서 gpt-5.2는 100%를 유지했으나, gemini-2.5-flash는 이미지 단독 입력 시 60%에서 텍스트와 이미지 결합 시 10%로, gemini-3-pro-preview는 70%에서 20%로 오히려 성능이 크게 낮아졌다. 연구자가 이미지를 텍스트로 전환하여 입력한 정보가 오히려 문제 해결에 간섭 요인으로 작용했을 수 있다.






Fig. 6. Content of item 14 [33].




Fig. 7. (Color online) Performance results for item 14 by model and mode.

따라서 학생이나 교사가 거대 언어 모델을 활용한 지능형 튜터링 시스템에 물리 문제를 질문할 때, 시각 자료(그래프, 회로도 등)를 주관적으로 해석하여 텍스트로 전환하기보다는 원본 이미지를 그대로 입력하고, 수치나 핵심 질문만을 보조적으로 텍스트에 포함하는 방식이 효과적임을 알 수 있다. 특히 멀티모달 통합 능력이 뛰어난 최신 모델일수록 이러한 명확한 역할 분담이 정보 간섭을 줄이고 문제 해결의 안정성을 높이는 데 도움이 될 수 있다.

Figure 6의 14번 문항은 동일 직선상에서 운동하는 두 물체(A, B)의 위치-시간( $x-t$ ) 그래프를 해석하여, 두 물체가 만나는 순간의 속력 비( $v_A/v_B$ )를 구하는 전형적인 운동학 문항이다. 동일한 가속도를 갖는 두 물체 A, B의 위치-시간 그래프에서 그래프의 의미를 정확히 해석하고 이를 등가속도 운동의 수식적 관계와 연결하는 능력이 필요하다. 이 문항을 해결하기 위해서는 거대 언어 모델이 텍스트와 이미지에 분산된 정보를 결합해서 처리할 수 있어야 한다. 먼저 시각적으로 제시된 두 개의 포물선 그래프에서 꼭짓점의 좌표( $t_0, 4d$ ), ( $2t_0, 2d$ )와 두 그래프의 교점을 파악해야 한다. 그리고 텍스트로 명시된 ‘같은 가속도로 등가속도 운동을 하는’이라는 결정적인 제약 조건을 결합하여 수식적으로 연립 방정식을 구성해야 한다.

14번 문항에 대한 각 모델별 정답률은 Fig. 7과 같다. 텍스트 입력 조건에서는 gpt-4.1(30%)을 제외한 o3, o4-mini,


gpt-5.2, gemini-3-pro-preview, claude-opus-4-6 등 대부분 모델이 100%의 높은 정답률을 보였다. 이는 그래프의 기하학적 정보가 텍스트 형태로 적절히 환원되어 입력될 경우, 모델의 수학적 연산 및 물리 공식 적용 능력이 적절히 작동함을 보여준다. 오류 사례를 분석해 보면, gpt-4.1은 초기 조건 및 운동 방정식은 비교적 타당하게 수립하였으나, 두 물체의 교점 시간을 구하기 위한 2차 연립 방정식 전개 과정에서 단순 대수 연산 오류가 반복적으로 나타났다. 이는 거대 언어 모델이 물리적 맥락을 파악하고 정확한 공식을 찾아도 수치 계산이나 다단계 계산에서 오류를 발생시켜 최종 오답에 이르는 비율이 높다는 여러 선행 연구의 결과와 일치하는 부분이다 [5,30]. 그리고 도출된 수학적 근이 물리적으로 유효한 시간인지 검증하지 않고 그대로 대입하여 오류를 범하는 사례가 많았다 [26]. 이 부분은 추론 모델에서는 거의 개선되어 이러한 종류의 오류는 발생하지 않았다.

이미지 입력 조건에서 gpt-4.1은 10%, o3는 40%의 낮은 정답률을 보였다. 반면 o4-mini, gpt-5.2, gemini-3-pro-preview, claude-opus-4-6은 정답률이 100%였다. 일부 초기 모델의 경우 선행 연구 [1]와 같이, 모델의 시각 인코더가 그래프 특성(포물선의 곡률 등)에서 문제 해결에 필요한 정보를 추출하지 못해, 곡선의 형태, 꼭짓점 위치인 ( $t_0, 4d$ ), ( $2t_0, 2d$ ) 등의 정보를 정량적으로 구조화하는 데 어려움을 보였다. 반면 최신 모델은 그래프의 기하학적 의미를 물리식으로 변환하는 능력이 크게 향상되었다. 특히 동일 가속도 조건에서도 속력이 0이 되는 시점이 각각 다르다는 점을 파악하는 것이 중요한 데 이 부분에서 성능 차이가 발생하였다.

텍스트와 이미지를 함께 입력하는 조건에서 gpt-4.1(70%)을 제외한 나머지 6개 모델이 모두 100%의 정답률을 보였다. 그래프 시각 자료를 해석할 때, 명시적인 텍스트 프롬프트가 시각 정보의 모호성을 제거하고 추론의 방향성을 정해주게 되므로 텍스트 정보가 그래프 해석의 방향성을 제공하고, 이미지는 정량적 관계를 보완해 주는 상호 보완적 역할을 했음을 알 수 있다. 특히 이 문제는 그래프만 보고 식을 세우기보다는, 문제 설명 속 조건(같은 가속도, 속력이 0이 되는 시점 등)을 함께 고려해야 정확한 비를 구할 수 있으므로, 멀티모달 통합이 효과적으로 작동한 사례라 할 수 있다.

그림에 대한 해석이 중요했던 11번 문항과 비교하면 차이를 볼 수 있다. 11번 문항에서는 텍스트 기반 추론에서 오류가 많지만, 14번 문항은 텍스트 기반에서도 상위 모델은 완전한 성능을 보였다. 이는 동일하게 그림에 대한 해석이 중요하지만, 14번 문항이 공간적 경로를 추적하는

19. 그림과 같이 빗면의 높이가  $15h$  인 지점에 질량이  $m$  인 물체 A를 가만히 놓는다. A는 빗면의 마찰 구간 I를 등속도로 지난 후, 높이가  $9h$  인 평면 위에 정지해 있던 질량이  $2m$  인 물체 B와 충돌한 후 정지한다. B는 충돌 후 빗면의 마찰 구간 II를 등속도로 지난다. 점 p와 q, r과 s는 각각 I, II의 양 끝점이다. p, s의 높이는 각각  $2H$ ,  $H$ 이고, q와 r의 높이는 서로 같다. II에서 손실되는 B의 역학적 에너지는 I에서 손실되는 A의 역학적 에너지의 2배이다. p에서 A의 운동 에너지와 s에서 B의 운동 에너지는 서로 같다.



$H$ 는? (단, 물체의 크기, 공기 저항, 마찰 구간 외의 모든 마찰은 무시한다.) [3점]

- ①  $\frac{23}{5}h$     ②  $\frac{14}{3}h$     ③  $\frac{19}{4}h$     ④  $\frac{24}{5}h$     ⑤  $5h$

Fig. 8. Content of item 19 [33].




Fig. 9. (Color online) Performance results for item 19 by model and mode.

문제라기보다는 주어진 정보를 수학적으로 구조화하는 능력이 중심인 문제였기 때문으로 보인다. 즉, 광학 문제는 시각적 경로 해석이 핵심이었고, 14번 문항은 등가속도 운동에 대한 수식적 모델링이 문제 해결의 핵심이었다. 따라서 문제 유형에 따라 모델의 강점이 다르게 나타난다고 볼 수 있다.

Figure 8의 19번 문항은 수능 물리학 문항 중에서 가장 복잡하고 복잡한 문항 중에 하나이다. 물체 A와 B가 빗면과 수평면을 따라 운동하고, 마찰 구간을 통과한 후 충돌하는 등 많은 역학적 사건이 순차적으로 일어나는 문항으로, 물체의 복잡한 공간 배치와 함께 “II에서 손실되는 B의 역학적 에너지는 I에서 손실되는 A의 역학적 에너지의 2배이다”와 같은 결정적인 제약 조건이 텍스트로 여러 개 존재한다. 문제를 해결하기 위해서는 역학적 에너지 보존, 마찰에 의한 에너지 손실, 충돌 과정, 질량 차이, 그리고 구간별 에너지 손실 비율 등을 복합적으로 고려해야 하고,

특히 구간 I과 II에서의 에너지 손실 관계, p와 s에서의 운동 에너지 동일 조건, 그리고 높이 관계를 함께 추론해야 한다.

19번 문항에 대한 각 모델별 정답률은 Fig. 9와 같다. 텍스트 입력 조건에서 gpt-4.1은 70%의 정답률을 보여 비교적 높은 성능을 보였지만 완벽하지는 않다. 반면 o3, o4-mini, gpt-5.2, gemini-3-pro-preview, claude-opus-4.6은 모두 100%의 정답률을 보여 안정적인 해결 능력을 보였다. gemini-2.5-flash는 정답률이 80%로 비교적 높은 수준이다. 이는 대부분의 모델이 문제의 핵심인 다양한 조건이 복합적으로 제시된 상황에서 에너지 보존식을 체계적으로 세우는 데 있어 문제 조건을 충분히 구조화할 수 있음을 의미한다.

이미지 입력 조건에서는 gpt-4.1의 정답률이 40%로 크게 낮아진다. 이는 그림 속 높이( $15h$ ,  $9h$ ,  $2H$ ,  $H$  등)와 구간 구분(I, II)을 정량적으로 추출하고 관계식을 세우는 데 어려움이 있었음을 보여준다. o3, o4-mini, gpt-5.2, gemini-3-pro-preview 등 대다수의 최신 모델은 이미지 입력 조건에서도 100%의 정답률을 보여, 이미지 환경에서도 뛰어난 물리적 모델링 능력을 나타냈다. 이 문제는 단순 도식 해석이 아니라, 그림을 물리적 상태 변화의 순서도 해석해야 한다는 점에서 높은 수준의 이미지 인식 능력이 필요하다. 반면, gpt-4.1(40%)과 gemini-2.5-flash(70%)는 텍스트 결합 모드에 비해 이미지 단독 모드에서 성능이 뚜렷하게 낮아졌다. 이는 많은 도면 기호( $15h$ ,  $9h$ ,  $2m$  등)와 많은 텍스트가 혼재된 시각적 환경에서는 정보를 구조화하여 추출하는 과정에서 문제가 발생할 수 있음을 알 수 있다. 그러나, 19번 문항은 다단계 에너지 추론 문제임에도 불구하고 최신 언어 모델들은 매우 높은 정확도를 보인다. 특히 텍스트와 이미지가 결합된 환경에서는 거의 모든 모델이 정답을 찾았다. 이는 고난도 역학 문제에서도 모델의 수식 구성 능력과 조건 통합 능력이 높은 수준에 도달했음을 보여준다.

이 문항의 오류 사례를 분석해 보면, 흥미롭게도 gpt-4.1은 계산 편의를 위해 높이  $h_q$ 와  $h_r$ 이 같다는 등의 문항에 명시되지 않은 가정을 임의로 도입하기도 하고, gemini-2.5-flash에서는 정답인  $24/5h$ 를 도출하기 위해, 중간 단계에서 틀린 계산이 있었음에도 불구하고 마치 그것이 의도된 과정인 것처럼 정답에 끼워 맞추려는 경향을 보이기도 하였다. 그리고 많은 오답 사례를 보면 이 문항에서만 특이한 조건인 마찰 구간에서 등속도로 지난다는 사실에서 논리적인 혼란을 겪었다. 그래서 일부는 “문제가 성립할 수 없다”는 결론을 내리고 풀이를 중단하거나 논리가 완전히 어긋나는 결론에 도달하기도 하였다. 이처럼 거대 언어 모델이 혼란하지 않은 특별한 조건에서는 어려움을 겪는 것을 알 수 있다 [3].

Table 3. Classification of error types by problem-solving phase.

| Problem solving phase   | Associated error type         | Primary cognitive cause                                      |
|-------------------------|-------------------------------|--------------------------------------------------------------|
| 1. Representation phase | Visual parsing error          | Failure to structurally organize visual information          |
|                         | Hallucinated assumption error | Arbitrary interpretation or creating non-existent conditions |
| 2. Modeling phase       | Conceptual error              | Mis-selection of laws or superficial pattern matching        |
|                         | Modeling error                | Over-simplification or failure to integrate constraints.     |
| 3. Execution phase      | Mathematical error            | Logical flaws in algebraic derivation or reasoning limits    |
| 4. Interpretation phase | Inconsistency error           | Confirmation bias to match a specific choice                 |
|                         | Validation error              | Lack of physical intuition to verify plausibility            |

앞서의 문항들과 비교해 보면, 11번 문항은 텍스트 기반 입력만으로는 거의 문제를 해결하지 못한 반면, 14번 문항은 텍스트 기반에서도 상위 모델은 안정적인 성능을 보였다. 19번 문항은 14번과 유사하게 텍스트 기반에서도 높은 성능을 보였으며, 추론 단계가 더 복잡하지만 전반적으로 높은 정답률을 유지하였다. 이 문항이 공간적 경로 추적보다는 에너지 보존 법칙이라는 명확한 물리 원리에 기반하고 있기 때문으로 보인다. 2번 문항과 19번 문항은 공통으로 텍스트 입력만으로도 대부분의 모델이 80–100%의 높은 정답률을 보였다. 이는 문제의 핵심 논리나 요구 사항이 텍스트 안에 이미 충분히 명시되어 있는 형태이면 거대 언어 모델이 해당 문항을 비교적 안정적으로 해결할 수 있음을 의미한다. 반면, 이미지 입력 조건에서는 gpt-4.1이 2번 문항에서 20%, 19번 문항에서 40%의 낮은 정답률을 보여 뚜렷한 한계를 드러냈다. 이는 gpt-4.1과 같은 초기 모델이 시각 자료에 포함된 텍스트와 도식 정보를 구조화하여 문제 해결에 활용하는 기초적인 시각 처리 능력에서 한계를 지니고 있음을 보여준다. 그리고 claude-opus-4-6은 기하 광학적 추론 문항에서 특히 낮은 성능을 보였다.

### 3. 물리 문제 해결 단계별 오류 유형 분류

앞서 분석한 2번, 11번, 14번, 19번의 풀이 과정에서 나타난 주요 오류를 거대 언어 모델의 물리 문제 해결 추론 과정의 단계에 따라 표상 구성 단계, 물리 모형 설정 단계, 수학적 연산 단계, 물리적 해석 단계별로 분류할 수 있다. Table 3은 이것을 분류한 결과를 정리한 것이다.

먼저 표상 구성 단계에서의 오류는 문제를 읽고 문제의 텍스트와 도식으로부터 초기 조건을 추출하는 단계에서 발생하는 유형이다. 이 단계에서는 특히 멀티모달 입력 환경에서 시각적 정보를 정확히 인식하지 못하는 한계로 발생하는 시각적 정보 판독 오류(주로 gpt-4.1에서 발생)나 시각 정보의 모호성을 해소하려는 과정에서 거대 언어 모델의

‘환각’이 실제로 주어지지 않은 조건이나 변수를 임의로 생성하는 환각적 가설 또는 변수 도입의 오류가 발생하였다 [30].

두 번째로 물리 모형 설정 단계에서의 오류는 물리적 상황을 수식화는 과정에서 발생하는 유형이다. 이 단계에서는 물리 법칙을 잘못 선택하거나, 원리에 대한 깊은 이해 없이 텍스트의 패턴(예: ‘반대 방향=인력’)에 의존하여 범하는 개념적 오류나 복잡한 물리 상황을 수식화하는 과정에서 상황을 과도하게 단순화하거나(예: 2차원 경로를 1차원으로 치환), 다중 제약 조건을 논리적으로 통합하지 못하는 물리적 모델링 오류를 범하기도 하였다.

세 번째는 수학적 연산 단계의 오류이다. 설정된 모형을 수리적으로 해결하는 단계에서 나타나는 유형으로, 논리적 추론의 부족으로 단순 대수 연산 오류 및 부호 적용 실수를 나타내기도 하였다.

마지막으로 물리적 해석 단계에서의 오류로서 계산 결과를 물리적 상황과 연결하고 타당성을 검토하는 과정에서 발생하는 유형이다. 풀이 과정에서 중대한 논리적 또는 수학적 오류가 발생했음에도 불구하고, 정답 도출이라는 목적에만 과적합되어 최종 결과와 과정을 억지로 끼워 맞추는 오류인 논리적 비일관성 오류나 도출된 해가 물리적으로 가능한지에 대한 검증이 이루어지지 않아, 현실적 맥락에서 성립하지 않는 결론에 도달하는 타당성 검토 오류가 발생하였다 [15].

그러나 본 연구는 거대 언어 모델의 물리 문제 해결 과정에서 나타나는 오류를 생성된 해설을 바탕으로 분석하였다는 점에서, 모델의 내부 추론 과정을 직접적으로 규명하는 데에는 일정한 한계를 가진다. 특히 본 연구에서 활용한 분석은 모델이 생성한 최종 응답과 풀이 과정을 사후적으로 해석하는 방식에 기반하고 있어, 실제로 모델이 어떠한 인지적 추론 과정을 거쳐 결론에 도달했는지를 완전히 반영하지 못할 가능성이 있다. 따라서 향후 연구에서 모델의 중간 추론 과정에 대해 직접적인 분석을 통해 거대 언어 모델의 실제 추론 구조와 오류 발생 메커니즘을 보다 정밀하게 분석할 필요가 있다.

#### IV. 요약 및 시사점

본 연구는 거대 언어 모델이 한국어로 된 고등학교 수준의 물리학 선다형 문항을 멀티모달 입력 조건(텍스트, 이미지, 텍스트+이미지 결합)에서 어떠한 성능을 나타내는지를 평가하고, 그 과정에서 나타나는 인지적 특성과 한계를 분석하였다. 2026학년도 수능 물리학I 20개 문항을 대상으로 7종의 최신 거대 언어 모델을 검증한 결과, 물리학 문제 해결 능력은 거대 언어 모델의 세대와 추론 모델 여부에 따라 뚜렷한 성능 차이를 보였다. 그러나 한국어 텍스트 기반 추론 능력만 놓고 보면, 상위 모델은 이미 매우 높은 수준에 도달해 단순 계산형 문항이나 조건이 텍스트로 명확히 제시된 문항에서는 모델 간 성능 차이가 거의 나타나지 않았으며, 인간 상위권 학생에 근접한 수행 특성을 보였다. 반면 고난도 문항으로 갈수록 모델 세대 간 성능 격차가 분명하게 나타났다.

둘째, 그림 해석이 핵심이 되는 문항에서는 이미지 해석 능력이나 텍스트와 이미지 정보를 결합하는 능력이 모델 성능을 좌우하는 가장 핵심적인 요소였다. 비교적 초기 모델인 gpt-4.1은 입력 방식에 따라 성능 편차가 크게 나타났고, 특히 이미지 정보 처리에서 낮은 성능을 보였다. claude-opus-4-6도 이미지 입력에서는 다소 낮은 정답률을 보였다. 반면에 연구의 시점에서 가장 최상위 추론 모델에 해당하는 gpt-5.2와 gemini-3-pro-preview는 세 가지 다른 입력 조건 모두에서 85~95% 이상의 정답률을 유지하며 안정적인 높은 성능을 보였다. 최신 거대 언어 모델이 방대한 텍스트 패턴을 단순히 재구성하는 것을 벗어나 복잡한 물리적 현상을 개념화하고 수리적으로 모델링할 수 있으며, 시각적인 정보와 텍스트 정보를 결합하여 추론하는 능력이 크게 향상되었음을 보여준다.

셋째, 물리학 문항이 요구하는 능력(개념 추론, 공간 기하학적 해석, 수식 모델링 등)에 따라 거대 언어 모델의 작동 양상과 한계가 다르게 나타났다. 예를 들어, 2번 문항(자성 추론)이나 19번 문항(복합 역학 시스템)과 같이 문제 해결에 필요한 핵심 단서와 물리적 제약 조건이 텍스트로 제시된 명제 중심의 문항에서는 대부분의 모델이 완벽에 가까운 추론을 수행했다. 반면, 11번 문항(광학 전반사)과 같이 기하학적 광경로의 해석과 공간 지각이 필수적인 문항에서는 텍스트 입력만으로는 문제 해결을 못했으며, 최상위 수준의 최신 모델만이 정답을 도출해 냈다. 14번 문항(운동학 그래프)에서는 텍스트(가속도 조건)와 시각 정보(포물선의 기하학적 특성)를 결합하여 연립 방정식을 구성해야 하는데, 이 과정에서 텍스트는 시각 정보의 모호성을 줄이고 해석의 방향을 제시하는 역할을 하였으며, 이러한 상호 보완적 역할이 문제 해결의 핵심 요소였다.

넷째, 전반적으로 텍스트와 이미지 정보를 함께 제공할 때 정확도가 더 높아지는 경향이 있었다. 특히 운동학 그래프를 해석하는 14번 문항처럼 이미지 정보와 텍스트가 상호 보완적 역할을 하는 경우가 문제 해결에서 중요한 역할을 하였다. 그러나 텍스트 정보와 시각 정보가 논리적으로 충돌하면 일부 모델에서는 성능이 하락하는 현상이 나타나기도 하였다.

결과적으로 최신 모델들은 고난도 한국어로 된 고등학교 수준의 물리학 문제에서 상당히 안정적인 성능을 보이며, 고교 및 대학 수준의 물리 지식과 높은 수준의 추론 능력을 갖춘 것으로 나타났다. 따라서 본 연구의 결과는 향후 물리 교육 현장에서 거대 언어 모델을 도입하고 활용하는 방식에 많은 변화가 있어야 함을 시사한다. 특히 거대 언어 모델이 기존의 기대 이상의 높은 성능을 보인다는 점에서, 이를 교육적으로 적극 활용할 수 있을 가능성과 과도하게 의존하거나 남용하는 문제를 함께 고려해야 한다.

우선 거대 언어 모델은 초기에 환각 현상에 대한 우려로 인하여, 교육적 활용에 있어서 다소 신중한 태도가 유지되어 왔다. 그러나 앞서 살펴보았듯이, 최근의 모델은 텍스트 입력이나 이미지 입력 모두에서 적어도 고등학교 수준의 문항을 매우 정확하게 해결하는 성능을 보였다. 따라서 이러한 모델을 기반으로 개인화된 시스템을 개발하여 개인화된 학습 지원 도구로서의 가능성을 검토할 수 있으며, 이를 활용하는 다양한 교수학습 모델도 가능할 것이다. 그리고 학생들이 본인이 풀던 문제의 그림을 카메라로 촬영하여 질문하는 방식의 활용도 충분히 가능하다. 물론 본 연구 결과에서 인공지능이 이미지 속의 복잡한 물리 기호를 누락하거나, 그래프를 잘못 해석하여 물리적 가정을 할 위험을 완전히 배제할 수는 없다. 따라서 학생에게 문제의 핵심 조건을 텍스트로 보완하여 설명하도록 하거나, 인공지능이 인식한 시각 정보를 다시 확인 받는 상호작용적 검증 인터페이스를 갖추도록 할 필요가 있다. 이러한 장치가 갖추어진다면 거대 언어 모델의 문제 해결 성능과 교육적 활용 가능성은 더욱 높아질 수 있을 것이다.

그러나 최근 시험이나 과제에서 인공지능을 활용한 부정행위가 문제가 되고 있다. 거대 언어 모델의 높은 성능은 역설적으로 학생들의 학습 과정에 부정적인 영향을 끼칠 수 있다. 학생들은 복잡한 물리 현상을 이해하기 위해 겪어야 할 필수적인 인지적 갈등과 숙고의 과정을 생략한 채, 정답을 빠르게 생성해 내는 인공지능에 연산과 추론을 과도하게 의존할 우려가 있다. 따라서 물리 교육에서 인공지능을 학습 도구로 적극 활용하되 학생의 기본적인 물리 개념 이해와 문제 해결 능력을 기르는 과정이 약화되지 않도록 균형 있게 접근할 필요가 있다. 시험이나 과제를 계획할



때도 인공지능 활용의 범위를 명확히 설정하는 한편, 인공지능을 활용하는 과제뿐만 아니라 활용할 수 없는 과제나 시험을 개발해서 제공해야 한다. 그리고 물리 교육 현장에서 인공지능의 오류를 단순히 제거해야 할 대상이 아니라, 학생의 이해를 심화시키는 교육의 기회로 활용할 수도 있을 것이다. 학생들이 인공지능의 답변을 비판적으로 검토하고 한계를 분석하는 과정은 물리적 개념과 현상을 깊이 이해하도록 하는 기회가 될 수 있다. 즉, 인공지능의 불완전성을 검증하고 해석하는 활동 자체가 물리 교육에서 의미 있는 학습 경험이 될 수 있다.

또한, 인공지능이 복잡한 연립 방정식을 세우고 기하학적 광경로를 해석하여 정확한 답을 도출하는 데 탁월한 성능을 보인다면, 기존의 정형화된 계산 및 정답 도출 중심의 평가는 더 이상 학생의 물리적 역량을 측정하는 타당한 도구가 될 수 없을 것이다 [6]. 앞으로 물리 학습 평가는 인공지능이 쉽게 수행할 수 있는 닫힌 문제를 푸는 능력 중심에서 벗어나, 현실 세계의 비구조화된 상황에서 물리적 변인을 스스로 설정하는 물리 모델링 유형, 실험을 설계하고 데이터를 해석하는 유형, 그리고 도출된 결과가 현실 세계에서 가지는 물리적 의미를 평가하는 유형 등으로 전환될 필요가 있다.

선행 연구를 살펴보면, 현재의 거대 언어 모델을 평가하는 대부분의 벤치마크가 영어 기반의 텍스트 중심으로 구성되어 있다 [32]. 따라서 향후에 한국어에 특화된 언어 모델을 개발하고 이를 평가할 수 있는 환경을 마련하며, 인공지능의 한국어 환경의 물리 교육에 도입을 촉진하기 위해서는 언어 모델의 추론 능력을 정확히 평가할 수 있는 한국어 멀티모달 물리 문항 벤치마크를 구축할 필요가 있다. 특히 본 연구는 선다형 문항과 이미지 데이터를 중심으로 모델의 문제 해결 능력을 평가했다. 연구에서 사용된 수능 물리 문항은 고등학교 물리학 선다형 문항의 전형적인 형태를 보여준다는 점에서 하나의 벤치마크로 기능할 수 있다. 그러나 현재 서술형 문항은 학교 현장에서 사용되는 유형과 형식이 매우 다양하므로, 이에 대해서는 별도의 벤치마크를 구축할 필요가 있다. 그래야만 서술형 문항의 채점이나 피드백 생성과 같은 영역에서 인공지능 모델의 활용 가능성을 더 타당하게 평가할 수 있기 때문이다.

## REFERENCES

- [1] G. Polverini and B. Gregorcic, How understanding large language models can inform the use of ChatGPT in physics education, *Eur. J. Phys.* **45**, 025701 (2024).
- [2] A. Vaswani *et al.*, Attention is all you need, *Adv. Neural Inf. Process. Syst.* **30**, 5998 (2017).
- [3] Y. Zhang *et al.*, ABench-Physics: Benchmarking physical reasoning in LLMs via high-difficulty and dynamic physics problems, arXiv:2507.04766.
- [4] K. Feng *et al.*, Physics: Benchmarking foundation models on university-level physics problem solving, *Proceedings of the Findings of the Association for Computational Linguistics: ACL 2025*, edited by W. Che, J. Nabende, E. Shutova and M. T. Pilehvar (Vienna, Austria, July 2025), pp. 11717–11743.
- [5] J. Ding, Y. Cen and X. Wei, Using large language model to solve and explain physics word problems approaching human level, arXiv:2309.08182.
- [6] P. Tschisgale *et al.*, Evaluating GPT- and reasoning-based large language models on Physics Olympiad problems: Surpassing human performance and implications for educational assessment, *Phys. Rev. Phys. Educ. Res.* **21**, 020115 (2025).
- [7] X. Zhai, M. Nyaaba and W. Ma, Can generative AI and ChatGPT outperform humans on cognitive-demanding problem-solving tasks in science?, *Sci. Educ.* **34**, 649 (2025).
- [8] H. Jho, Leveraging generative AI in physics education: Addressing hallucination issues in large language models, *New Phys.: Sae Mulli* **74**, 812 (2024).
- [9] S. Küchemann *et al.*, Large language models—Valuable tools that require a sensitive integration into teaching and learning physics, *Phys. Teach.* **62**, 400 (2024).
- [10] A. Sperling and J. Lincoln, Artificial intelligence and high school physics, *Phys. Teach.* **62**, 314 (2024).
- [11] J. Lee and S. Ryu, Trends in domestic and international research on the use of generative AI in science education: An analysis of its application in class design and as a learning tool, *J. Korean Assoc. Sci. Educ.* **45**, 19 (2025).
- [12] T. Min and B. Lee, Comparison of scoring results for physics descriptive items in GPT language models based on prompts, *New Phys.: Sae Mulli* **74**, 504 (2024).
- [13] J. Lee, Research on automated scoring for short constructed-response questions through fine-tuning ChatGPT, *New Phys.: Sae Mulli* **75**, 381 (2025).

- [14] S. Savage and N. S. Rebello, Using an LLM to investigate students' explanations on conceptual physics questions, *Proceedings of the Physics Education Research Conference 2025*, edited by A. Pawl, J. P. Zwolak and A. E. Leak (Washington, DC, August 6–7, 2025), pp. 399–404.
- [15] G. Kortemeyer, Toward AI grading of student problem solutions in introductory physics: A feasibility study, *Phys. Rev. Phys. Educ. Res.* **19**, 020163 (2023).
- [16] Y. Wei *et al.*, Research on intelligent grading of physics problems based on large language models, *Educ. Sci.* **15**, 116 (2025).
- [17] A. Lieb and T. Goel, Student interaction with Newt-Bot: An LLM-as-tutor chatbot for secondary physics education, *Proceedings of the Extended Abstracts of the CHI Conference on Human Factors in Computing Systems* (Honolulu, HI, USA, 2024), Article 614.
- [18] T. Wan and Z. Chen, Exploring generative AI assisted feedback writing for students' written responses to a physics conceptual question with prompt engineering and few-shot learning, *Phys. Rev. Phys. Educ. Res.* **20**, 010152 (2024).
- [19] M. Jang *et al.*, Case study of high school physics class development utilizing ChatGPT, *New Phys.: Sae Mulli* **74**, 779 (2024).
- [20] H. K. Park and J. Park, Lesson plan development for pre-service elementary school teachers through collaboration with AI: Focused on ChatGPT, *New Phys.: Sae Mulli* **74**, 215 (2024).
- [21] H. Maus *et al.*, Developing and evaluating a large language model-based automated feedback system grounded in evidence-centered design for supporting physics problem solving, arXiv:2512.10785.
- [22] A. Meyer, T. Bleckmann and G. Friege, Automatic feedback on physics tasks using open-source generative artificial intelligence, *Int. J. Sci. Educ.* **1** (2025).
- [23] W. Yeadon and T. Hardy, The impact of AI in physics education: A comprehensive review from GCSE to university levels, *Phys. Educ.* **59**, 025010 (2024).
- [24] C. G. West, Advances in apparent conceptual physics reasoning in GPT-4, arXiv:2303.17012.
- [25] G. Polverini and B. Gregorcic, Performance of ChatGPT on the test of understanding graphs in kinematics, *Phys. Rev. Phys. Educ. Res.* **20**, 010109 (2024).
- [26] R. Loubet *et al.*, Using large language models for solving textbook-style thermodynamic problems, *Comput. Chem. Eng.* **204**, 109333 (2026).
- [27] W. Yeadon and D. P. Halliday, Exploring Durham University physics exams with large language models, arXiv:2306.15609.
- [28] X. Wang *et al.*, SciBench: Evaluating college-level scientific problem-solving abilities of large language models, arXiv:2307.10635.
- [29] OpenAI, GPT-4 Technical Report, arXiv:2303.08774.
- [30] K. D. Wang *et al.*, Examining the potential and pitfalls of ChatGPT in science and engineering problem-solving, *Front. Educ.* **8**, 1330486 (2024).
- [31] X. Pang *et al.*, Physics reasoner: Knowledge-augmented reasoning for solving physics problems with large language models, *Proceedings of the 31st International Conference on Computational Linguistics*, edited by O. Rambow *et al.* (Abu Dhabi, UAE, January 2025), pp. 11274–11289.
- [32] G. Kortemeyer *et al.*, Multilingual performance of a multimodal artificial intelligence system on multisubject physics concept inventories, *Phys. Rev. Phys. Educ. Res.* **21**, 020101 (2025).
- [33] College Scholastic Ability Test (CSAT), <https://www.suneung.re.kr/>.
- [34] F. Shi *et al.*, Large language models can be easily distracted by irrelevant context, arXiv:2302.00093.